

Abschlussbericht Konzepte des Machine Learnings

Entwicklung eines probabilistischen LSTM/RNN-Modells zur Vorhersage von Photovoltaik-Einspeisung auf Basis von SMARD-Marktdaten

Projektbericht

Vorgelegt von **Valentin Bäumer** und Jan-Christian Raabe (106980)

Im Sommersemester 2026

Konzepte des Machine Learnings [SS26]

Betreut von Prof. Dr. Christian-Arved Bohn

Kommentiert [JR1]: Bitte ergänzt noch eure Matrikelnummern

Inhaltsverzeichnis

1	Einleitung und Zielsetzung.....	1
1.1	Welches Problem soll das Projekt lösen?	1
1.2	Interesse und Motivation	2
1.3	Was soll demonstriert werden?.....	2
1.4	Stand der Technik	2
2	Arbeitspakete	4
2.1	AP1: Recherche nach geeigneten Datenquellen und explorative Datenanalyse	4
2.2	AP2: Modellarchitektur und probabilistisches Training (LSTM vs. RNN).....	4
2.3	AP3: Evaluierung, Modellvergleich und Erklärbarkeit.....	4
2.4	AP4: Containerisierung und Projektdokumentation	5
3	Vorgehensweise und Projektumsetzung.....	6
3.1	Technische Implementierung und Software-Architektur	6
3.2	Kick-Off	7
3.3	Zeitplan.....	8
4	Ergebnisse und Diskussion	9
4.1	Explorative Datenanalyse.....	9
4.1.1	Datensatzstruktur und Vollständigkeit.....	9
4.1.2	Deskriptive Analyse der Kernkomponenten.....	10
4.1.3	Mathematische Stationaritätsprüfung.....	12
4.1.4	Tensor-Transformation für das überwachte Lernen	12
4.2	Qualitativer und quantitativer Vergleich der Architekturen	13
5	Fazit und Reflexion	17
6	Literatur	18
7	Prompt Verzeichnis	19

1 Einleitung und Zielsetzung

Aufgrund wetterbedingter Fluktuationen stehen Netzbetreiber durch die fortschreitende Integration volatiler, erneuerbarer Energien vor wachsenden Planungsunsicherheiten. Klassische statistische Modelle liefern meist nur starre Punktprognosen, sodass unerwartete Abweichungen zu einem erhöhten Bedarf an kostenintensiver Ausgleichsenergie führen können, um die Netzstabilität sicherzustellen.

Daher besteht das Ziel dieser Arbeit in der Entwicklung, Implementierung und Evaluierung einer probabilistischen, multivariaten Zeitreihenvorhersage für Photovoltaik (PV)-Erzeugung, die statt einer reinen Punktprognose einen dynamischen Sicherheitskorridor (Konfidenzintervall 80 %) mittels einer Quantil-Regression (Pinball Loss) berechnet.

Dabei fokussiert sich der Gang der Untersuchung auf folgende Aufgaben:

- Vergleich der Architekturen Long Short-Term Memory (LSTM) und Recurrent Neural Networks (RNN): Dabei wird empirisch analysiert, ob ein LSTM oder ein klassisches RNN eine höhere Präzision bei der Modellierung des Unsicherheitsbandes aufweist und sich somit besser für die kurzfristige solare Prädiktion eignet.
- Erklärbarkeit und Transparenz: Mittels der Permutation Feature Importance ist mathematisch offenzulegen, welche physikalischen Wechselwirkungen und Einflussfaktoren die Vorhersage der Modelle maßgeblich steuern, um die Black-Box-Struktur der neuronalen Netze für den Handelseinsatz transparenter zu gestalten.
- Validierung der Dynamik: Im Vergleich mit realen historischen Daten soll demonstriert werden, dass sich das prognostizierte Unsicherheitsband bei volatilen Wetterlagen ausdehnt und sich bei stabilen Bedingungen verengt, um dem Netzmanagement ein verlässliches Instrument zur Risikominimierung anzubieten.

1.1 Welches Problem soll das Projekt lösen?

Das Projekt soll das Problem der Planungsunsicherheit bei volatilen, erneuerbaren Energien (speziell Photovoltaik) lösen. Die Kernproblematik besteht darin, dass herkömmliche statistische Modelle oft nur eine starre Punktprognose liefern. Liegt das Modell beispielsweise wetterbedingt (z. B. durch plötzliche Bewölkung) falsch, müssen Netzbetreiber in Sekunden-schnelle extrem teure Ausgleichsenergie einkaufen, um einen Blackout zu verhindern. Durch

den Einsatz eines probabilistischen multivariaten LSTM und eines RNN berechnet das Modell in dieser Arbeit über eine Quantils-Regression (Pinball Loss) einen dynamischen Sicherheitskorridor (80%-Konfidenz-intervall). Der Netzbetreiber soll daher sofort sehen können, wie sicher sich die künstliche Intelligenz (KI) bei der Prognose ist, um das finanzielle Risiko zu minimieren.

1.2 Interesse und Motivation

Es soll ein multivariates Modell verwendet werden, das die physikalischen Wechselwirkungen im Stromnetz lernt. Mittels der Permutation Feature Importance soll mathematisch messbar und für den Menschen transparent gemacht werden, welche Faktoren (z. B. die Tageszeit) gerade den größten Einfluss auf die Solarprognose haben. Das schafft das notwendige Vertrauen für den echten Handelseinsatz.

1.3 Was soll demonstriert werden?

Es soll gezeigt werden, wie die KI im Vergleich zur Realität abschneidet. Das Modell soll demonstrieren, wie sich das Unsicherheitsband bei wechselhaftem Wetter ausdehnt und bei stabilen Wetterlagen verengt, mit dem Ziel die Planungssicherheit zu erhöhen.

1.4 Stand der Technik

Die probabilistische Zeitreihenprognose fluktuierender erneuerbarer Energien gewinnt zur Vermeidung der kostenintensiven Ausgleichenergien und zur Sicherung der Netzstabilität massiv an Bedeutung. Klassische, statistische Ansätze wie Autoregressive integrierte Moving-Average-Modelle (ARIMA) liefern primär starre Punktprognosen. Zur Unsicherheitsmodellierung etablierten sich sogenannte Generalized Autoregressive Conditional Heteroskedasticity- (GARCH-) Modelle, die die zeitlich veränderliche Volatilität der Residuen abbildet. Solche linearen Verfahren stoßen jedoch bei der Erfassung nicht-linearer meteorologischer Wechselwirkungen auf Grenzen.^[1]

Mit der Entwicklung der Deep Learning Architekturen wurden sogenannte Quantils-Regressions-Neuronale-Netze (QRNN) eingeführt, die statistische Quantilsschätzungen mittels Pinball Loss in neuronale Strukturen integrieren. Das in dieser Arbeit entwickelte Framework erweitert

diesen Ansatz deterministisch um eine zeitliche Sequenzkomponente rekurrenter Netzarchitekturen (LSTM und RNN), um die physikalische Trägheit der Wetterbedingungen abzubilden.^[1]

Im Vergleich zu bereits bestehenden industriellen und akademischen State-of-the-Art-Modellen lässt sich der gewählte Ansatz abgrenzen:

- Das LSTM-basierte DeepAR (Amazon) Framework nutzt eine parametrische probabilistische Vorhersage, indem die Parameter einer hypothetischen Verteilung (Gauß- oder t-Verteilung) geschätzt werden. Die Verteilung der PV-Einspeisung ist durch die harten Nullgrenzen in den Nachtstunden extrem schief und nicht-normalverteilt. Daher bietet der in dieser Arbeit genutzte nicht-parametrische Pinball-Loss-Ansatz mathematisch eine deutlich höhere Flexibilität.^[2,3]
- Sogenannte Temporal Fusion Transformer (TFT) nutzen Aufmerksamkeitsmechanismen zur multivariaten Vorhersage und bieten eine inhärente Erklärbarkeit. Das hier entwickelte Modell erreicht ein ähnliches Maß an Transparenz und Interpretierbarkeit, indem die Black-Box-Struktur der Netze über eine modellunabhängige Permutation Feature Importance mathematisch offengelegt wird.^[4]

2 Arbeitspakete

Im Folgenden werden die Arbeitspakete (AP) dargestellt, die in diesem Projekt definiert wurden.

2.1 AP1: Recherche nach geeigneten Datenquellen und explorative Datenanalyse

Bevor entsprechende Architekturen trainiert werden können, müssen zunächst geeignete Datenquellen gefunden werden, die eine fehlerfreie und eine stationäre Datenbasis darstellen. Dabei gilt es folgende Aufgaben zu erledigen:

- Bereinigung der Daten (z. B. Transformation von String-Formaten in numerische Werte)
- Explorative Datenanalyse (EDA) zur Extraktion zyklischer Features
- Analyse der Korrelationen
- Stationaritätsprüfung

Ziel: Generierung einer strukturierten und validierten Eingangsmatrix im Tensorformat und dynamisch generierte EDA-Visualisierungen.

2.2 AP2: Modellarchitektur und probabilistisches Training (LSTM vs. RNN)

Das Ziel besteht im Training der beiden konkurrierenden neuronalen Netze (LSTM/RNN). Hierzu soll eine Trainings-Pipeline konfiguriert werden (Early Stopping, Hyperparameter-Setup), die als Ergebnis die erfolgreich trainierten Modellgewichte für beide Architekturen speichert und automatisiert den Trainingsverlauf protokolliert.

2.3 AP3: Evaluierung, Modellvergleich und Erklärbarkeit

Im Fokus steht ein quantitativer und qualitativer Vergleich der Modellleistungen und die Aufdeckung der Feature-Wichtigkeiten. Um die präzise Architektur zu ermitteln, werden die Verluste (Pinball Loss) auf den Testdaten berechnet und für das LSTM und RNN gegenübergestellt. Durch Implementierung der Permutation Feature Importance soll der mathematische Einfluss

der einzelnen Eingangsvariablen auf die Vorhersage charakterisiert werden. Schlussendlich sollen die finalen Prognosedigramme, die das reale Einspeiseprofil inklusive des prognostizierten, dynamischen Unsicherheitsbandes abbilden, generiert werden.

2.4 AP4: Containerisierung und Projektdokumentation

Die finale Pipeline soll in eine plattformunabhängige Laufzeitumgebung überführt werden. Dabei soll eine fehlerfreie Datensynchronisation sichergestellt werden. Im Fokus steht eine vollständig reproduzierbare, containerbasierte Anwendung mit umfassender Projektdokumentation.

3 Vorgehensweise und Projektumsetzung

3.1 Technische Implementierung und Software-Architektur

Das finale Produkt ist eine modularisierte, containerisierte End-to-End-Pipeline, deren Orchestrierung über eine interaktive Streamlit-Webanwendung erfolgt. Die gesamte Architektur ist in eine plattformunabhängige Docker-Laufzeitumgebung eingebettet. Dabei erfolgt eine Datensynchronisation zwischen den Verzeichnissen `/smard-daten/input` und `/smard-daten/output`. Nach dem Upload einer unskalierten SMARD-Rohdaten-CSV im Frontend wird die Berechnungs-Pipeline über ein Multiprocessing-Protokoll sequentiell verarbeitet. Konsolenausgaben und Fehlermeldungen werden dynamisch abgefangen und alle generierten Artefakte (validierte CSV-Daten, serialisierte Skalierungs-Metadaten und hochauflösende PNG-Visualisierungen) in das Output-Verzeichnis abgelegt. Die Pipeline gliedert sich wie folgt:

- Explorative Datenanalyse und Feature Engineering (`eda.py`): In diesem Skript werden die Rohdaten geladen, bereinigt und länderspezifische numerische String-Formate über eine Zeitstempel-Analyse isoliert. Neben einer automatisierten Auflösungserkennung wird ein zyklisches Feature Engineering durchgeführt. Die Rhythmen werden über Sinus- und Kosinus-Transformationen der Stunde mathematisch als kontinuierliche Wellenfunktionen operationalisiert.
- Daten-Transformation und Sequenzerstellung: Die multivariate Feature-Matrix (bestehend aus PV, Wind Onshore, Erdgas und zyklischen Zeitkomponenten) wird durch die Modellskripte über ein gleitendes Fenster für das überwachte Lernen transformiert. Dabei passt sich die Fenstergröße dynamisch an die erkannte Auflösung an, sodass die Historie immer exakt eine Sequenz von 24 Stunden umfasst. Die Daten werden auf das Intervall $[0,1]$ normiert und in ein dreidimensionales PyTorch-Tensorformat der Dimension (B, T, D) überführt. Dabei steht B für die Batch-Größe, T für die Sequenzlänge und D für die Feature-Anzahl. In dieser Architektur erfolgt die Datenaufteilung über einen verschachtelten Split (80 % Training- (davon 10 % Validierung zur Steuerung des Early Stopping) und 20 % Testdaten).
- Probabilistische rekurrente Modellarchitekturen (`train_lstm.py` und `train_rnn.py`): Im Fokus stehen hier das LSTM und das RNN. Beide Netze verfügen über ein verdecktes Layout mit zwei rekurrenten Schichten, 128 Hidden-Units und einer Dropout-

Regularisierung von 20 % zur Vermeidung von Overfitting. Das klassische RNN schreibt die sequentiellen Informationen über einfache lineare Transformationen des verdeckten Zustands fort, während das LSTM eine komplexe Gating-Struktur (Input-, Forget- und Outout-Gate) nutzt, damit zeitliche Abhängigkeiten und meteorologische Trägheiten gespeichert werden können.

Im Gegensatz zu klassischen Punktprognosen besitzt die finale lineare Schicht des Netzwerkes drei Ausgabeneuronen, die vorab definierte Quantile schätzen. Dabei erfolgt das Training nicht-parametrisch über die Minimierung des Pinball Loss (Quantils-Verlustfunktion). Die Optimierung wird durch den Adam Optimizer mit einer Lernrate von 0.0005 gesteuert, der an einen dynamischen Lernraten-Scheduler gekoppelt ist. Der Early-Stopping-Mechanismus bricht das Training zur Absicherung der Generalisierungsfähigkeit ab, sofern der Validierungsverlust über 25 Epochen stagnierte. Nachdem das Modell mit der Prediction Interval Coverage Probability (PICP) evaluiert wurde, wird die Black-Box-Struktur der Netzwerke über die Permutation Feature Importance aufgebrochen, die den mathematischen Einfluss jedes einzelnen Features direkt auf den Pinball Loss misst.

3.2 Kick-Off

Im Rahmen des Kick-Offs wurde der Projektumfang, die Meilensteine und die Kommunikation im Team definiert.

Definition des Projektumfangs: Konzeption, Implementierung und containerisierte Bereitstellung einer Pipeline zur probabilistischen Zeitreihenvorhersage der Energieeinspeisung auf Basis historischer Zeitreihendaten. Dabei sollen die unskalierten Rohdaten automatisiert bereinigt, um zyklische sowie meteorologische Merkmale erweitert und in ein geeignetes Tensorformat überführt werden. Der Fokus liegt auf dem modellseitigen Training und einem empirischen Leistungsvergleich zweier Architekturen (LSTM und RNN), um statt starrer Punktprognosen dynamische 80 % Konfidenzintervalle zu generieren.

Meilensteine: Folgende Meilensteine wurden im Rahmen dieses Projektes definiert:

- Entwicklung eines Konzeptes zur Datenbereinigung und explorativen Datenanalyse
- Entwicklung zweier containerbasierten Architekturen LSTM/RNN

- Vergleich beider Architekturen mit Zeitreihendaten unterschiedlicher Länge (unterschiedlicher Zeiträume) und Auflösung (z. B. viertelstündige oder stündliche Auflösung)

Kommunikationsstrukturen: Für ein effizientes und agiles Vorgehen im Team wurden feste Kommunikationsstrukturen beschlossen. Die Koordination und Fortschrittsbesprechung basiert auf wöchentlichen Sitzungen, in denen der aktuelle Fortschritt besprochen, Aufgaben verteilt und strategische Entscheidungen getroffen werden.

3.3 Zeitplan

Die gesamte Projektlaufzeit wurde für insgesamt elf Wochen geplant:

- Die Bearbeitung des AP1 wurde für KW 17 bis 19 geplant und beinhaltet die Definition des Projektes, die Recherche nach geeigneten Daten und die EDA.
- Zur Bearbeitung von AP2 und AP4 wurde KW 20 bis 22 angesetzt und beinhaltet neben dem Erstellen der LSTM/RNN Architekturen auch die ersten Testläufe.
- Für KW 23 bis 25 wurde die Bearbeitung des AP3 angesetzt. Hier liegt der Fokus auf dem qualitativen und quantitativen Vergleich beider Architekturen mit Datensätzen unterschiedlicher Zeiträume und Auflösung (z. B. Viertelstunde vs. Stunde).

KW/Ereignisse	17	18	19	20	21	22	23	24	25	26	27
Kick-Off und AP1 Erste Ideensammlung Definition der Projektziele Recherche nach geeigneten Daten Explorative Datenanalyse											
AP2 und AP4 Erstellen eines LSTM und RNN Training des RNN und LSTM Erste Testläufe Containerisierung											
AP3 Quantitativer und qualitativer Vergleich Testen unterschiedlicher Datensätze · kurze vs. lange Zeiträume · Variation der Datenauflösung											
AP4 Behebung letzter Fehler Projektdokumentation											

4 Ergebnisse und Diskussion

4.1 Explorative Datenanalyse

Die unskalierten Rohdaten in Abbildung 4.1 zeigen den gesamten kontinuierlichen Zeitverlauf vom 09. April 2026 bis zum 19. April 2026 im 15-Minuten Takt. Die Photovoltaik (PV)-Erzeugung besteht aus einzelnen, scharfen Ausschlägern (Tagespeaks), während die Windenergie eine wellenartige Struktur zeigt.




Abbildung 4.1: Solar- und Wind Onshore-Energieerzeugung über elf Tage (Rohdaten) vom 09.04.2026 bis zum 19.04.2026.

Die unskalierten Rohdaten zeigen einen kontinuierlichen Zeitverlauf. Die PV-Erzeugung besteht aus solaren Tagespeaks, während die landbasierte Windenergie einen stochastischen, wellenartigen Verlauf aufweist.

4.1.1 Datensatzstruktur und Vollständigkeit

Die Überprüfung der Struktur des [SMARD-Datensatzes](#) zeigt eine lückenlose Zeitreihe von insgesamt 1056 Beobachtungen im Zeitraum vom 09. April 2026 bis zum 19. April 2026. Da der Datensatz in einer viertelstündigen Auflösung vorliegt, lässt sich der Datenumfang mathematisch validieren:

- 96 Beobachtungen am Tag (24 Stunden x 4 Intervalle/Stunde)

- Elf Tage Beobachtungszeitraum (bzw. zehn volle Tage plus Randstunden nach der Bereinigung)

Die insgesamt 19 Spalten (Features) weisen keine fehlenden Werte auf, was eine stabile Grundlage für das Machine Learning bietet.

4.1.2 Deskriptive Analyse der Kernkomponenten

Die statistischen Kennzahlen der primären volatilen Energieträger offenbaren fundamentale Unterschiede in der jeweiligen physikalischen Verteilungscharakteristik, siehe Abbildung 4.2:

- PV: Der Mittelwert der solaren Einspeisung liegt bei 2056.23 MWh mit einer maximalen Peak-Leistung von 12070.45 MWh. Die Standardabweichung von 3353.81 MWh übersteigt den Mittelwert, was auf inhärente Volatilität der Solarenergie hindeutet. Das 25 %-Quantil liegt bei exakt 0.00 MWh und das 50 %-Quantil bei 0.01 MWh. Statistisch gesehen wird in über 50 % des gesamten Beobachtungszeitraums faktisch keine solare Einspeisung beobachtet, was eine direkte Folge der Nachtstunden ist. Herkömmliche Modelle neigen dazu die Spitzenwerte drastisch zu unterschätzen. Dies rechtfertigt den in dieser Arbeit gewählten probabilistischen Quantils-Ansatz (Pinball Loss).
- Wind Onshore: Die landbasierte Windkraft zeigt einen Mittelwert von 1562.65 MWh und ein Maximum Wert von 7729.33 MWh. Das 25 %-Quantil liegt bei 286.38 MWh. Im Gegensatz zur PV bricht die Windkraftproduktion nachts nicht systematisch ein und stellt somit einen kontinuierlichen stochastischen Prozess dar, der unabhängig der astronomischen Zeiten operiert.

Wird das aggregierte, durchschnittliche Tagesprofil in Abbildung 4.2 betrachtet, treten diese Charakteristiken deutlich hervor. Die blaue PV-Kurve zeigt die klassische Glockenform und beginnt exakt bei 6:00 Uhr morgens zu steigen und erreicht ihr Maximum um 12:00 bis 13:00 Uhr während des höchsten Sonnenstandes. Bis 20:00 Uhr fällt die Kurve wieder auf die Nulllinie ab. Zwischen 20:00 und 6:00 Uhr verläuft die Kurve exakt auf der Nulllinie, da die Sonne in der Nacht nicht scheint. Im aggregierten Mittel verläuft die Windkraft relativ konstant in einem Band zwischen 1300 und 2400 MWh. Es gibt hier im Gegensatz zur Solarenergieproduktion keinen festen Tag-/Nacht-Rhythmus.

Ergebnisse und Diskussion




Abbildung 4.2: Durchschnittliches Tagesprofil der PV und Wind Onshore Energieerzeugung aggregiert über elf Tage.




Abbildung 4.3: Korrelationen zwischen den Energiequellen dargestellt in einer Heatmap (Korrelationsmatrix).

Die Korrelationsmatrix (Heatmap) in Abbildung 4.3 zeigt die linearen Korrelationskoeffizienten nach Pearson zwischen allen im Datensatz enthaltenen Erzeugungsquellen. Zwischen der PV und der Onshore-Windkraft zeigt sich eine schwach negative Korrelation (etwa -0.15). Diese Beobachtung deckt sich mit der meteorologischen Realität, da stark windprägende Tiefdruckgebiete häufig mit einer erhöhten Wolkenbedeckung einhergehen, die die solare Einstrahlung drastisch dämpft.

Da die Kernkraftwerke in dem betrachteten Zeitraum des Jahres 2026 stillgelegt sind, weist dieses Feature eine Varianz von 0 auf. Mathematisch führt dies bei der Berechnung des Pearson-Koeffizienten zu nicht definierten Ausdrücken. Daher bleibt die entsprechende Zeile und Spalte visuell leer.

4.1.3 Mathematische Stationaritätsprüfung

Vor dem Training der Modelle muss sichergestellt werden, dass die Zeitreihe stationär ist, da stochastische Trends zu einer Scheinkorrelation und instabilen Gradientenstrukturen führen können. Im Rahmen dieser Arbeit wurde der Augmented Dickey-Fuller-Test (ADF-Test) auf die PV-Erzeugungsdaten angewendet. Dabei liefert die Teststatistik einen empirischen Wert von -6.5474. Dieser Wert liegt unter dem kritischen Schwellenwert, wodurch ein asymptotischer p -Wert von 0.0000 resultiert. Somit kann bei einem Signifikanzniveau von $\alpha = 1\%$ ausgesagt werden, dass die Zeitreihe im statistischen Sinne stationär ist.

4.1.4 Tensor-Transformation für das überwachte Lernen

Für das sequentielle Training des LSTMs und RNNs wurden die bereinigten Daten über ein gleitendes Fenster in ein dreidimensionales Tensorformat überführt. Es wurde eine Fenstergröße von 96 Zeitschritten definiert, was exakt der Periode eines vollen Tages (24 Stunden $\times$ 4 Intervalle) entspricht.

Bedingt durch diese Transformation verringert sich die Anzahl der effektiv nutzbaren Datenpunkte mathematisch bedingt von 1056 auf 960 Sequenzdaten.

- Somit besitzt die Feature-Matrix X die Dimensionen $(960, 96, D)$, wobei D für die Anzahl der Eingangsmerkmale steht. Das Modell liest somit 960-mal ein Fenster aus 96 aufeinanderfolgenden Viertelstunden ein.

- Der Zielvektor y besitzt die Dimension (960,) und repräsentiert den drauffolgenden 97. Zeitschritt.

Es deckt sich mit der physikalischen Realität, dass der erste zu erlernende Wert der Matrix exakt 0.0 MWh beträgt, da nach den ersten 96 Zeitschritten (Tag 1) die Prädiktion für den Folgetag exakt um Mitternacht 0:00 Uhr startet. Die ist der Zeitpunkt, an dem die solare Erzeugung zwingend null betragen muss. Das verifiziert die logische und chronologische Integrität der gesamten Datenpipeline.

4.2 Qualitativer und quantitativer Vergleich der Architekturen

Das Modelltraining wurde mit drei Datensätzen unterschiedlicher Auflösung durchgeführt:

- Zeitraum 09.04. bis 19.04.2026 in 15-minütiger Auflösung (April 2026)
- Zeitraum 09.04. bis 19.04.2026 in 60-minütiger Auflösung (April 2026)
- Zeitraum 01.03. bis 19.04.2026 in 15-minütiger Auflösung (März-April 2026)

Die Lernkurven beider Architekturen (LSTM – rechts und RNN – links) sind in Abbildung 4.4 gezeigt:




Abbildung 4.4: Lernkurven beider Architekturen (LSTM und RNN) im direkten Vergleich. Rot – 15-minütige Auflösung (April 2026), pink - 15-minütige Auflösung (März-April 2026) und blau – 60-minütige Auflösung (April 2026). Die durchgezogenen Kurven entsprechen der Validierung und die gestrichelten Kurven entsprechen dem Training.

Ergebnisse und Diskussion




Abbildung 4.5: Probabilistische Photovoltaik-Vorhersage im direkten Architekturvergleich (Datensatz April 2026, 15-minütige Auflösung).




Abbildung 4.6: Probabilistische Photovoltaik-Vorhersage im direkten Architekturvergleich (Datensatz April 2026, 60-minütige Auflösung).

Die Vorhersagen und 80 %igen Konfidenzbänder im direkten Architekturvergleich des April 2026 Datensatzes mit 15-minütiger Auflösung ist in Abbildung 4.5 und mit 60-minütiger

Auflösung in Abbildung 4.6 gezeigt. Vorhersagen und Konfidenzbänder des März-April 2026 Datensatzes sind in Abbildung 4.7 dargestellt.




Abbildung 4.7: Probabilistische Photovoltaik-Vorhersage im direkten Architekturvergleich (Datensatz März-April 2026, 15-minütige Auflösung).

Die kombinierten Lernkurven zeigen den Verlauf des Pinball-Loss über die Epochen, wobei nach den Architekturen LSTM (Abbildung 4.4 links) und RNN (Abbildung 4.4 rechts) getrennt wurde. In beiden Modellen zeigt sich ein stabiles Konvergenzverhalten, das durch einen integrierten Early-Stopping-Mechanismus vorzeitig abgebrochen wurde, nachdem der Validierungsverlust stagnierte.

Die Auswertung der Vorhersagediagramme in den Abbildungen 4.4 bis 4.7 zeigen den präzisen solaren Glockenverlauf und wie sich die Unsicherheitsbänder (80 % Konfidenzintervalle) verhalten. Im April 2026 Datensatz (15-minütige Auflösung) treffen sowohl LSTM als auch RNN den realen Verlauf (schwarze Linie), siehe Abbildung 4.5. Das hellblaue (LSTM) bzw. hellgrüne (RNN) Band schmiegt sich extrem an die Kurven an. Insgesamt weisen die Modelle bei dieser hohen Auflösung und klarem Wetter eine sehr hohe Vorhersagesicherheit auf. Nachts verengt sich dieses Band auf die Nulllinie. Somit haben die Modelle gelernt, dass ohne Sonnenlicht keine solare Varianz existieren kann. Der April 2026 Datensatz (60-minütige Auflösung) zeigt, dass das LSTM am ersten Tag die absolute Spitze leicht überschätzt, während das RNN diese Spitze präzise trifft, siehe Abbildung 4.6. Da sich durch die stündliche Aggregation die

mathematische Unsicherheit des Modells pro Zeitschritt erhöht, führt dies dazu, dass das Unsicherheitsband signifikant breiter ist als im 15-Minuten-Szenario. Der März-April 2026 Datensatz (15-minütige Auflösung) weist über den längeren Testzeitraum die höchste Robustheit auf. Der Median schmiegt sich fehlerfrei an die unterschiedlichen Peak-Höhen der Testtage an. Bedingt durch den längeren Zeitraum und die größere Datenmenge, ist das Unsicherheitsband extrem scharf und schmal kalibriert. Das Modell hat durch die erhöhte Datenmenge eine so hohe statistische Sicherheit gewonnen, dass der Risikokorridor minimiert werden konnte. Die PICP bleibt jedoch hoch.

Insgesamt liefern die Modelle keine starren Werte, sondern einen dynamischen Sicherheitskorridor. Je feiner die Auflösung und je größer der Datensatz, desto mehr schärft sich das Konfidenzband. Genau diese Dynamik liefert dem Netzbetreiber den gewünschten Mehrwert: an der Breite des Konfidenzbandes kann sofort das mathematische Risiko für den Handelseinsatz abgeschätzt werden.

5 Fazit und Reflexion

Diese Arbeit demonstriert erfolgreich die Konzeption und Implementierung einer containerbasierten Machine-Learning-Pipeline zur probabilistischen PV-Einspeiseprognose auf Basis von SMARD-Zeitreihendaten. Mittels Verknüpfung von rekurrenten Schichten mit einem nicht-parametrischen Pinball Loss konnte ein dynamischer Risikokorridor konstruiert werden, der statt starrer Punktprognosen einen verlässlichen Sicherheitskorridor liefert.

Die empirischen Ergebnisse erlauben folgende Kernkomponenten der Untersuchung zu bilanzieren:

- **Architekturvergleich:** Beide Architekturen können den solaren Verlauf präzise abbilden. Teilweise zeigt das LSTM aufgrund seiner komplexen Gating-Struktur eine höhere Robustheit bei der Speicherung langreichweitiger meteorologischer Abhängigkeiten, was sich in einer stabileren Konvergenz im Training widerspiegelt.
- **Einfluss von Datenvolumen und Auflösung:** Durch die zeitliche Granularität und die Datenmenge wird die Schärfe des Unsicherheitsbandes maßgeblich bestimmt. Die grobe 60-Minuten-Auflösung führt zu signifikant breiteren Bändern, während die Erweiterung der Datenbasis eine präzise Verengung des Sicherheitskorridors bewirkt. Das Modell passt die statistische Unsicherheit dynamisch an den Informationsgehalt der Daten an.
- **Erklärbarkeit:** Mittels Permutation Feature Importance wurde die mathematische Black-Box-Struktur der tiefen neuronalen Netze erfolgreich aufgebrochen. Der Nachweis, dass neben den solaren Basis-Features auch multivariate Wechselwirkungen (z. B. die physikalisch begründete, schwache negative Korrelation zur Windkraft) den Verlust steuern, schafft die benötigte Transparenz für den realen Handelseinsatz.

Mit dem entwickelten System können wetterbedingte Planungsunsicherheiten im Stromnetz mathematisch exakt quantifiziert werden. Die Kombination aus Docker-Containerisierung, Streamlit-Oberfläche und interpretierbaren Machine-Learning-Strukturen bietet die valide Grundlage, um den Bedarf an kostenintensiver Ausgleichsenergie effektiv zu minimieren.

6 Literatur

- [1] T. Hong, P. Pinson, S. Fan, H. Zareipour, A. Troccoli, R. J. Hyndman, *Int. J. Forecast.* **2016**, *32*, 896–913.
- [2] D. Salinas, V. Flunkert, J. Gasthaus, T. Januschowski, *Int. J. Forecast.* **2020**, *36*, 1181–1191.
- [3] B. Xiong, Y. Chen, D. Chen, J. Fu, D. Zhang, *Appl. Energy* **2025**, *382*, 125294.
- [4] B. Lim, S. Ö. Arik, N. Loeff, T. Pfister, *Int. J. Forecast.* **2021**, *37*, 1748–1764.

7 Prompt Verzeichnis

Prompt-Verzeichnis aller verwendeten Prompts, die zur Erstellung dieser Arbeit eingesetzt wurden.

Tabelle 2: Detailliertes Prompt-Verzeichnis aller in dieser Arbeit verwendeten Prompts (Nummer, Datum bzw. Version des Prompts, Wortlaut des verwendeten Prompts, das verwendete Tool oder Modell und das Kapitel, wo der Prompt im Text verwendet wurde.

Nr.	Datum/Version	Verwendeter Prompt	Tool/Modell	Verwendung im Text