


Probabilistische Energiedaten- vorhersage

Technische Projektvorstellung: Von SMARD-Daten zu
Quantilprognosen mit LSTM und RNN

von Jan-Christian Raabe und Valentin Bäumer



Gliederung

01

Motivation und Ziel

Warum probabilistische Prognosen für Photovoltaik sinnvoll sind.

02

Gesamtpipeline

Wie Daten, Modelle, Metriken und Dashboard zusammenarbeiten.

03

Verfahren im Detail

Die einzelnen Pipeline-Schritte werden unter die Lupe genommen.

04

Livedemo

Das Streamlit-Dashboard zeigt Ergebnisse, Plots und Protokolle.

05

Stärken & Grenzen

Was das Projekt gut kann und was kritisch bleibt.

Hinweis zu den Darstellungen und Zahlen

Alle Diagramme, Metriken und Modellvergleiche dieser Präsentation beziehen sich auf einen konkreten SMARD-Ausschnitt.

Was genau wurde ausgewertet?

Zeitraum: 09.04.2026 00:00 bis 19.04.2026 23:00
Datenbasis: 264 Stundenwerte, 14 Energiespalten
Quelle: SMARD Downloadcenter, Marktdaten DE, CSV

Die Downloadparameter bestimmen den Zeitraum. Ein längerer oder verschobener Download erzeugt eine andere Datenbasis.

264

Stunden im Rohdatensatz

60 min

zeitliche Auflösung

240

24h-Fenster / Sequenzen

48

Testpunkte für Metriken

Was bedeutet das für die Interpretation?

- RNN- und LSTM-Werte sind Ergebnisse dieses Laufs, keine allgemeingültige Rangliste.
- Mehr Tage, ein anderes Jahr oder zusätzliche Wetterdaten können PICP, RMSE, Breite und Winkler Score verändern.

Motivation und Ziel

Kernproblem

Photovoltaik schwankt stark durch Tageszeit, Jahreszeit und Wetter.
Für Planung ist deshalb nicht nur der wahrscheinlichste Wert relevant, sondern auch der plausible Bereich.

18,2 %

Anteil von PV an der
Bruttostromerzeugung
in Deutschland (1)




Ziel des Projekts

Aus historischen SMARD-Daten entsteht ein lokales System für probabilistische PV-Prognosen. Die Unsicherheit wird als Intervall berechnet und in einem Dashboard verständlich ausgegeben.

Gesamtpipeline

Die Komponenten greifen als reproduzierbare Pipeline ineinander.



Upload: Die Datenbasis wird festgelegt

SMARD liefert die historischen Energiemarktdaten, die Pipeline verarbeitet sie lokal.

DIE DATEN

Was ist SMARD?

SMARD ist die Marktdatenplattform der Bundesnetzagentur. Sie stellt Zeitreihen zu Stromerzeugung, Verbrauch, Markt und Systemdaten bereit. Für unser Projekt ist vor allem die historische PV-Erzeugung relevant.

01 Was wird hochgeladen?

Pflicht: SMARD-CSV mit Zeitstempel und Erzeugungsspalten.
Optional: Wetter-CSV mit numerischen Wettervariablen.



02 Was gilt es zu beachten?

PV ist Zielgröße und zugleich historische Eingabe.
Wind und Erdgas dienen als Kontext für Energiesystemzustände.

Upload → lokale Verarbeitung → Output-Ordner

Alle Ergebnisse bleiben reproduzierbar im Projekt: bereinigte CSVs, Modelle, Scaler, Plots, Metriken und Protokolle.

EDA: Die Zeitreihe wird fachlich geprüft



Bereinigung

- Deutsche Zahlenformate werden numerisch.
- Zeitstempel werden geparkt und sortiert.
- Leere oder unvollständige Endbereiche werden gekappt.

Auflösung

- Die Pipeline erkennt automatisch die zeitliche Auflösung.
- Daraus entsteht immer ein 24h-Fenster.
- Beispiel: 60 Minuten → Fenstergröße 24.

Tagesprofil

- PV folgt einem klaren Tagesrhythmus.
- Wind verhält sich weniger strikt zyklisch.
- Das begründet explizite Zeitfeatures.


Korrelationen

- Heatmap als Plausibilitätscheck.
- Sie ersetzt keine Kausalität, zeigt aber Muster.
- Auffälligkeiten werden sichtbar.

EDA ist hier kein Selbstzweck: Sie entscheidet, ob die Daten überhaupt sinnvoll trainierbar sind.

Features: Zeitlogik wird explizit lernbar

Zeitliche Muster und Kontextinformationen werden explizit lernbar gemacht.



Welche Features?

- PV-Historie als wichtigste Ausgangsinformation.
- Zeitfeatures: Stunde, Wochentag, Wochenende.
- Kontext: Wind Onshore und Erdgas.

Warum zyklisch?

- Uhrzeit und Wochentag sind Kreise, keine linearen Zahlen.
- 23 Uhr und 0 Uhr liegen direkt nebeneinander.
- Sinus/Cosinus kodieren diese Nachbarschaft.

Begründung der Feature-Auswahl

Die Features verbinden historische PV-Erzeugung, zeitliche Struktur und weitere Energiesystemgrößen.

Split & Scale: Datenleckage wird verhindert

Erst zeitlich trennen, dann Scaler nur auf Trainingsdaten fitten.

Train

173 Sequenzen

Validierung

19

Test

48

chronologische Reihenfolge bleibt erhalten

Warum so?

- Zeitreihen dürfen nicht zufällig gemischt werden.
- Sonst würde zukünftige Information indirekt ins Training gelangen.

Wie genau?

- MinMaxScaler wird nur auf dem Trainingsbereich gefittet.
- Validierung und Test werden danach nur transformiert.

Fensterlogik

- Jede Eingabe besteht aus 24 Stunden Vergangenheit.
- Das Ziel ist der nächste PV-Wert nach diesem Fenster.

`scaler.fit(train) → transform(train, validation, test)`

Modelle: Quantile statt Punktprognose

LSTM und RNN werden fair mit gleicher Datenbasis, gleichem Loss und gleichen Quantilen verglichen.

RNN



- Rekurrentes neuronales Netz mit verborgenem Zustand.
- Liest Sequenzen Schritt für Schritt.
- Einfacher Aufbau, weniger Parameter.
- Guter Vergleichspunkt für das komplexere LSTM.

LSTM

- Erweiterte rekurrente Architektur mit Gates.
- Soll längerfristige Abhängigkeiten stabiler speichern.
- Geeignet für Zeitreihen mit verzögerten Mustern.
- Hier: gleiche Pipeline wie RNN.

Probabilistischer Output


- Letzte Sequenzrepräsentation geht in eine lineare Ausgabeschicht.
- Ausgabe sind drei Werte: $q0.1$, $q0.5$ und $q0.9$.
- $q0.1$ bis $q0.9$ bilden das zentrale 80%-Prognoseintervall.
- Rohquantile werden für die Ausgabe monoton sortiert.



Trainingsziel: Pinball Loss + Crossing Penalty · Optimizer: Adam · Early Stopping über Validierungsverlust

Evaluation: Fehler und Unsicherheit

Ein Intervall ist nur gut, wenn Abdeckung, Breite und Fehler gemeinsam plausibel sind.



58,3 %

LSTM PICP

4.907

LSTM RMSE

5.280

LSTM Breite

89,6 %

RNN PICP

1.804

RNN RMSE

5.723

RNN Breite

Wie wird bewertet?

- **PICP:** Liegen echte Werte im 80%-Intervall?
- **Intervallbreite:** Wie konservativ ist der Korridor?
- **Pinball Loss:** Sind die Quantile selbst gut geschätzt?
- **Winkler Score:** Bestraft breite und verfehlte Intervalle.

Wichtig: Ein niedriger RMSE allein reicht nicht. Bei probabilistischen Prognosen zählt auch, ob die Unsicherheit realistisch kalibriert ist.

Livedemo: Dashboard statt Ergebnisordner

Warum es hilft

- Die Outputs müssen nicht einzeln im Ordner gesucht werden.
- Metriken und Plots sind strukturiert zusammengeführt.
- Regelbasierte Interpretation ordnet Zahlen vorsichtig ein.

Was bewusst fehlt

- Keine generative KI/LLM-Analyse im Dashboard
 - Die Interpretation ist nachvollziehbar regelbasiert.
 - Damit bleibt die Bewertung reproduzierbar und erklärbar.

Demo-Übergang: Von der technischen Pipeline zur bedienbaren Anwendung.
<http://localhost:8501>

Limitierungen des Projektes

Das Projekt ist ein sauberer Prototyp, aber noch kein produktives Prognosesystem.

Keine echte Wetterprognose

Ohne Globalstrahlung, Bewölkung und Temperatur bleibt ein zentraler PV-Treiber außen vor.

Architekturen bewusst einfach

TFT, DeepAR oder Hybridmodelle wurden nicht implementiert.

Kein kausaler Erkläranspruch

Feature Importance zeigt Sensitivität, aber keine physikalische Ursache.

Was das Projekt gut kann

Die Stärke liegt in der vollständigen, nachvollziehbaren Pipeline.

End-to-End

Upload, Bereinigung, Training, Evaluation und Dashboard greifen ineinander.

Methodisch sauberer

Chronologischer Split und Scaler nur auf Trainingsdaten verhindern Datenleckage.

Probabilistisch

q0.1, q0.5 und q0.9 machen Unsicherheit sichtbar statt sie zu verstecken.

Vergleichbar

LSTM und RNN nutzen dieselbe Trainings- und Evaluationslogik.

Reproduzierbar

Seeds, Docker, Metrikdateien, Modellartefakte und Protokolle dokumentieren den Lauf.

Präsentierbar

Das Dashboard macht Ergebnisse direkt prüfbar und verständlich erklärbar.

Vielen Dank für eure Aufmerksamkeit!



Fragen?

Quellenverzeichnis

SMARD-Datensätze:

- <https://www.smard.de/home/downloadcenter/download-marktdaten/?downloadAttributes=%7B%22selectedCategory%22:1,%22selectedSubCategory%22:1,%22selectedRegion%22:%22DE%22,%22selectedFileType%22:%22CSV%22,%22from%22:1775685600000,%22to%22:1776635999999%7D>

Weitere Quellen:

- (1): <https://de.statista.com/statistik/daten/studie/250915/umfrage/anteil-der-photovoltaik-an-der-stromerzeugung-in-deutschland/>